

Diseño y Evaluación de un Agente Virtual Multimodal con Embodiment para Atención al Cliente de en Mediación Virtual basado en Generación Aumentada por Recuperación (RAG)

Entregable 2

Esteban Alonso León Rodríguez
Maestría Académica en Computación e
Informática Universidad de Costa Rica

Temas Especiales de Ingeniería de Sistemas de
Información:

Agentes Virtuales Inteligentes
Prof. Alexander Barquero Elizondo
San José, Costa Rica
1 de Junio, 2026

a) Resumen de Cambios desde el Entregable 1

A partir del feedback, se realizaron los siguientes cambios:

Problema y Motivación

- Se delimitó el alcance del agente a consultas técnicas sobre la plataforma Mediación Virtual, por ejemplo: acceso a cursos, carga de materiales, configuración de actividades, habilitación de cursos, etcétera.

Revisión de Literatura

- Se amplió la revisión a más de 20 fuentes, incorporando referencias fundamentales de embodiment y agentes conversacionales: Cassell et al. (2000), Bickmore y Picard (2005), ter Stal et al. (2020), Shin et al. (2019) y Chattopadhyay y MacDorman (2016).
- Se agregó literatura sobre uncanny valley para justificar la decisión de usar un avatar estilizado (VRoid) en lugar de hiperrealista.

Preguntas de Investigación

- Se separó RQ2 en dos métricas independientes: tiempo de resolución (medición objetiva) y tasa de éxito (registro de completitud).
- Se especificaron instrumentos formales: SUS para usabilidad, Godspeed para naturalidad y presencia social, NASA-TLX para carga cognitiva.

Arquitectura Técnica

- Se especificaron los componentes tecnológicos concretos: Gemini 2.5 Flash (LLM), gemini-embedding-001 (embeddings), ChromaDB (base vectorial), faster-whisper (STT), edge-tts (TTS), Unity WebGL (avatar VRoid/VRM).

b) Estado Actual del Agente

El prototipo implementado es una prueba de concepto funcional que integra todos los componentes de la arquitectura propuesta, aunque desde la entrega pasada algunos pasaran por cambios o incluso se añadieron nuevos componentes que no estaban especificados. El sistema es operacional en un entorno local. La interacción combina entrada por voz o texto, recuperación de contexto desde una base de conocimiento vectorial, generación de respuesta con Gemini 2.5 Flash y síntesis de voz sincronizada con animaciones faciales del avatar 3D.

Arquitectura del sistema implementado

Componente	Tecnología	Descripción
Interfaz de usuario	Streamlit (Python)	Interfaz web local con una columna para el avatar y otra para el chat (voz y texto).
STT	faster-whisper (local)	Transcripción de audio a texto ejecutada localmente. Modelo 'small', configurado para español.
LLM + RAG	Gemini 2.5 Flash + ChromaDB	El contexto recuperado (top-5 chunks por similitud coseno ≥ 0.4) se inyecta en el prompt junto al historial de conversación. Se recurrió a una versión de pago de Gemini para saltarse los rate limiters, especialmente en la elaboración de la base de conocimiento.
Base Vectorial	ChromaDB (persistente)	538 chunks indexados provenientes de 28 presentaciones Genially de los manuales de uso de la plataforma MV de METICS.
TTS	edge-tts	Síntesis de voz con voz es-CR-MaríaNeural (Costa Rica). Audio MP3 reproducido en browser y enviado al servidor de lipsync.
Lipsync server	Python + WebSockets	Servidor WebSocket que analiza la amplitud RMS del audio (30 FPS) y transmite valores de blendshapes a Unity.
Avatar 3D	Unity WebGL + Vroid/VRM	Avatar estilizado embebido como iframe en Streamlit. Recibe frames de blendshapes vía WebSocket y anima los músculos faciales de la boca en tiempo real.

Pipeline de datos RAG

La base de conocimiento fue construida a través del siguiente pipeline:

1. Extracción: texto de presentaciones Genially exportado por slide, con transcripción de videos embebidos.
2. Enriquecimiento: cada slide fue procesada con Gemini para generar enriched_title, summary y keywords semánticos. Esto corrigió títulos genéricos como 'Copia Copia Copia' y mejoró la recuperación.
3. Chunking: 1 slide = 1 chunk. El texto del chunk combina título enriquecido + resumen + contenido + keywords para maximizar la densidad semántica.
4. Indexado: 538 chunks vectorizados con gemini-embedding-001 e indexados en ChromaDB con métrica de distancia coseno.

Funcionalidades implementadas y pendientes.

Funcionalidad	Estado	Notas
Pipeline RAG (extracción → enriquecimiento → indexado)	Implementado	28 presentaciones, 538 chunks. Fue lo que me llevó más tiempo.
Chat por texto con historial conversacional	Implementado	Historial persistente en session_state
STT con faster-whisper	Implementado	Modelo 'small', español forzado
TTS con edge-tts (voz neural)	Implementado	Voz es-CR-JuanNeural
Avatar 3D Unity WebGL	Parcial	Aunque existe un avatar en 3D de VRoid, este no era la solución principal. Se trabajó en un avatar “from scratch” en Blender, pero por cuestiones de tiempo se migró a la opción de VRoid por esta entrega. “Traté de volar muy cerca del sol profe”
Lipsync sincronizado con audio (RMS)	Parcial	Aunque si hay lipsync, hace falta refinarlo muchísimo. Tiene bastante delay y hay que mejorar las animaciones.
Sistema de fuentes con links a Genially	Implementado	Expander con similitud y URL
Estados visuales del avatar (escuchando / respondiendo)	Parcial	Solo animación de boca activa
Animación idle del avatar	Parcial	Avatar estático entre respuestas
Registro de logs y métricas del sistema	Pendiente	Necesario para evaluación
Integración con tickets reales de METICS-UCR	Pendiente	Actualmente usa material de manuales existentes.
Evaluación con participantes	Pendiente	Planificado para Entregable 3

c) Diseño Metodológico del Estudio

Se realizará una evaluación con expertos, complementada con una sesión de think-aloud estructurada. Este diseño fue elegido por las siguientes razones:

- La evaluación con usuarios reales requiere autorización del CEC de la UCR, lo cual excede el alcance temporal del curso.
- Una evaluación con expertos permite identificar problemas de usabilidad, naturalidad y coherencia del sistema antes de un estudio con usuarios finales, maximizando la calidad del prototipo con recursos limitados.
- El perfil de los expertos en este contexto incluye a asesores profesionales en comunicación, con especialidades en educación mediada por tecnologías, que como parte de su trabajo también se encargan de atentes consultas de usuarios de la plataforma Mediación Virtual. Además, estas personas fueron los encargados de elaborar los manuales disponibles en la página de METICS que fueron utilizados para alimentar el sistema RAG, por lo que tienen mucha experiencia en el uso y manejo de la plataforma de Mediación Virtual.

Condiciones

- **Condición Experimental (A):** Agente virtual multimodal con voz (STT/TTS), avatar 3D animado con lipsync y base de conocimiento RAG. Esta condición representa el sistema implementado en este entregable.
- **Condición de Control (B):** Interfaz conversacional basada únicamente en texto con acceso a RAG, sin componentes de voz ni representación visual. Esta condición representa el chatbot textual existente en Mediación Virtual.

d) Métricas

Pregunta de Investigación (RQ)	Variable / Constructo	Instrumento Validado	Tarea Asociada
RQ1. ¿Cómo impacta el uso de un agente virtual multimodal con voz y embodiment en la satisfacción y usabilidad percibida por los usuarios en comparación con un chatbot tradicional basado en texto?	Usabilidad percibida	SUS (System Usability Scale)	Resolver una consulta de soporte utilizando el sistema asignado (texto o multimodal)
	Satisfacción del usuario	meCUE / CSAT	Completar interacción completa de atención al cliente
	Presencia social y naturalidad	Godspeed Questionnaire Series	Interactuar con el agente mediante voz y avatar
RQ2. ¿Cómo influye la incorporación de memoria conversacional y capacidades multimodales en la eficiencia de resolución de tareas de atención al cliente?	Tiempo de resolución	Medición objetiva de tiempo	Resolver una tarea específica de soporte técnico
	Tasa de éxito	Registro de completitud de tarea	Completar exitosamente el escenario planteado
	Carga cognitiva	NASA-TLX	Resolver una tarea con múltiples pasos e instrucciones

e) Instrumentos de Recolección de Datos

- **SUS**

- **¿Qué mide?:** Usabilidad percibida del sistema.
- **Base bibliográfica:** Brooke (1996). SUS: A quick and dirty usability scale. En P. Jordan et al. (Eds.), Usability Evaluation in Industry (pp. 189-194). Taylor & Francis.
- **Administración:** Cuestionario de 10 ítems en escala Likert de 5 puntos (totalmente en desacuerdo a totalmente de acuerdo). Se aplica después de cada escenario de interacción.
- **Puntaje:** 0-100. Puntajes ≥ 68 indican usabilidad aceptable; ≥ 80.3 corresponde a 'excelente'.

- **Godspeed Questionnaire Series**

- **¿Qué mide?:** Percepción de naturalidad, animación y agrado del agente. Se utilizarán las subescalas Animacy y Likeability, relevantes para agentes conversacionales con embodiment.
- **Base bibliográfica:** Bartneck, C., Kulić, D., Croft, E., & Zoghbi, S. (2009). Measurement instruments for the anthropomorphism, animacy, likeability, perceived intelligence, and safety of robots. International Journal of Social Robotics, 1(1), 71-81.
- **Administración:** Diferencial semántico de 5 puntos. Se aplica después de interactuar con la condición experimental (A) para evaluar la percepción del avatar y la voz.

- **NASA-TLX**

- **¿Qué mide?:** Carga cognitiva subjetiva en 6 dimensiones: demanda mental, demanda física, demanda temporal, rendimiento, esfuerzo y frustración.
- **Base bibliográfica:** Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX (Task Load Index): Results of empirical and theoretical research. Advances in Psychology, 52, 139-183.
- **Administración:** Escala de 0-100 por dimensión. Se aplica al final de cada escenario en ambas condiciones. Se usará la versión Raw TLX (sin ponderación de dimensiones) para simplificar la administración con expertos.

- **CSAT y meCUE**

- **¿Qué mide?:** Satisfacción general del usuario con el sistema y calidad de la experiencia de uso.
- **Base bibliográfica:** Minge, M., Thüring, M., Wagner, I., & Kuhr, C. V. (2017). The meCUE questionnaire: A modular tool for measuring user experience. En S. Yamamoto (Ed.), Human Interface and the Management of Information (pp. 115-128). Springer.
- **Administración:** Se aplicarán 3 ítems del módulo de consecuencias de uso (intención de uso futuro, recomendación, satisfacción general) en escala Likert de 7 puntos, al final de la sesión completa.

- **Entrevista Semiestructurada**

- **¿Qué mide?:** Problemas de usabilidad, percepciones cualitativas sobre el avatar, la voz y la naturalidad de la interacción.
- **Base bibliográfica:** Ericsson, K. A., & Simon, H. A. (1993). Protocol Analysis: Verbal Reports as Data. MIT Press.
- **Administración:** Durante la sesión se pedirá a los expertos que verbalicen sus pensamientos mientras interactúan. Al finalizar ambos escenarios se realizará una entrevista de 10-15 minutos con preguntas guía sobre la percepción de naturalidad, confianza, ventajas y desventajas de cada condición.

Preguntas guía de la entrevista post-sesión:

- ¿Qué diferencias notó entre interactuar con el agente de texto y el agente multimodal?
- ¿El avatar y la voz hicieron la interacción más natural o más incómoda? ¿Por qué?
- ¿Cuánta confianza le genera el sistema para resolver una consulta real de Mediación Virtual?
- ¿Qué aspectos mejoraría para que el agente sea más efectivo como herramienta de soporte?

f) Protocolos de Interacción

Estructura de sesión

Cada sesión tendrá una duración estimada de 30 minutos y seguirá el siguiente orden:

Fase	Actividad	Duración
1. Bienvenida	Presentación del estudio, firma de consentimiento informado, instrucciones generales.	2 min
2. Calibración	El participante interactúa libremente con el sistema durante 2-3 minutos para familiarizarse.	2 min
3. Escenario 1	Condición A o B (contrabalanceado). Think-aloud activo.	8 min
4. Instrumentos E1	SUS + NASA-TLX para el Escenario 1.	2 min
5. Escenario 2	Condición opuesta a la del Escenario 1. Think-aloud activo.	8 min
6. Instrumentos E2	SUS + NASA-TLX + GQS + meCUE.	5 min
7. Entrevista	Entrevista semiestructurada post-sesión.	5 min

Escenario 1: Curso no visible en Mediación Virtual

Elemento	Descripción
Contexto	Asuma el rol de un estudiante universitario que acaba de matricular el curso 'Fundamentos de Educación Virtual' (código EV-1001) en la UCR. Al ingresar a Mediación Virtual, el curso no aparece en su lista de cursos activos. Necesita resolver esta situación antes de la primera lección, que es en 24 horas.

Elemento	Descripción
Tarea específica	Utilice el sistema asignado (texto o multimodal) para obtener información sobre por qué podría no aparecer el curso y qué pasos debe seguir para resolver el problema.
Resultado esperado	El participante obtiene una respuesta que menciona posibles causas (sincronización de matrícula, curso no habilitado por docente, problema de cuenta) y pasos de acción (verificar matrícula en SIUCR, contactar al docente, contactar a METICS). El agente debe recuperar información relevante del RAG sobre el proceso de acceso a cursos.
Criterio de éxito	El participante considera que la respuesta le permitiría resolver o escalar el problema sin intervención humana adicional.
Duración estimada	8-10 minutos

Escenario 2: Configuración de una actividad evaluativa

Elemento	Descripción
Contexto	Asuma el rol de un docente universitario que está preparando su curso en Mediación Virtual para el primer ciclo. Necesita crear una tarea de entrega de archivos con fecha límite, y no recuerda exactamente cómo configurar los permisos para que los estudiantes solo puedan entregar hasta la fecha indicada y no después.
Tarea específica	Utilice el sistema asignado para obtener instrucciones sobre cómo configurar una actividad de Tarea en Mediación Virtual con fecha límite de entrega estricta.
Resultado esperado	El agente recupera información sobre la configuración de actividades en Mediación Virtual: acceso al bloque de actividades, configuración de fechas, opciones de entrega tardía, y opciones de permisos. La respuesta incluye pasos secuenciales claros.
Criterio de éxito	El participante puede identificar los pasos necesarios para completar la configuración sin necesidad de buscar información adicional.
Duración estimada	8-10 minutos

Referencias

- Bartneck, C., Kulić, D., Croft, E., & Zoghbi, S. (2009). Measurement instruments for the anthropomorphism, animacy, likeability, perceived intelligence, and safety of robots. *International Journal of Social Robotics*, 1(1), 71–81. <https://doi.org/10.1007/s12369-008-0017-6>
- Benita, J., Vivek Charan Tej, K., Vinay Kumar, E., Venkata Subbarao, G., & Venkatesh, C. H. (2024). Implementation of retrieval-augmented generation (RAG) in chatbot systems for enhanced real-time customer support in e-commerce. *arXiv*. <https://doi.org/10.48550/arXiv.2410.02338>
- Bickmore, T. W., & Picard, R. W. (2005). Establishing and maintaining long-term human-computer relationships. *ACM Transactions on Computer-Human Interaction*, 12(2), 293–327. <https://doi.org/10.1145/1067860.1067867>
- Brooke, J. (1996). SUS: A quick and dirty usability scale. En P. Jordan, B. Thomas, B. Weerdmeester, & I. McClelland (Eds.), *Usability Evaluation in Industry* (pp. 189–194). Taylor & Francis.
- Cassell, J., Bickmore, T., Campbell, L., Vilhjalmsón, H., & Yan, H. (2000). Designing embodied conversational agents. En J. Cassell, J. Sullivan, S. Prevost, & E. Churchill (Eds.), *Embodied Conversational Agents* (pp. 29–63). MIT Press.
- Chattopadhyay, D., & MacDorman, K. F. (2016). Familiar faces rendered strange: Why inconsistent realism drives characters into the uncanny valley. *Journal of Vision*, 16(11), 7. <https://doi.org/10.1167/16.11.7>
- Chen, Y., Ji, S., Wang, H., Wang, Z., Chen, S., He, J., Xu, J., & Zhao, Z. (2025). WavRAG: Audio-integrated retrieval augmented generation for spoken dialogue models. *arXiv*. <https://doi.org/10.18653/v1/2025.acl-long.613>
- Ericsson, K. A., & Simon, H. A. (1993). *Protocol Analysis: Verbal Reports as Data*. MIT Press.
- Hart, S. G., & Staveland, L. E. (1988). Development of NASA-TLX (Task Load Index): Results of empirical and theoretical research. *Advances in Psychology*, 52, 139–183. [https://doi.org/10.1016/S0166-4115\(08\)62386-9](https://doi.org/10.1016/S0166-4115(08)62386-9)
- Hewitt, T., & Beaver, I. (2020). A case study of user communication styles with customer service agents versus intelligent virtual agents. *Proceedings of SIGDIAL*. <https://doi.org/10.18653/v1/2020.sigdial-1.11>
- Huang, M.-H., & Rust, R. T. (2018). Artificial intelligence in service. *Journal of Service Research*, 21(2), 155–172. <https://doi.org/10.1177/1094670517752459>
- Kraus, S., Oshrat, Y., & Aumann, Y. (2023). Customer service combining human operators and virtual agents: A call for multidisciplinary AI research. *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(13). <https://doi.org/10.1609/aaai.v37i13.26795>
- Langevin, R., Lordon, R. J., Avrahami, T., Cowan, B. R., Hirsch, T., & Hsieh, G. (2021). Heuristic evaluation of conversational agents. *Proceedings of the 2021 CHI Conference on Human Factors in Computing Systems*. <https://doi.org/10.1145/3411764.3445312>
- Liu, J., Lin, J., & Liu, Y. (2024). How much can RAG help the reasoning of LLM? *arXiv*. <https://doi.org/10.48550/arXiv.2410.02338>
- Mercer, A. J., Hollingsworth, B. T., & Velez, C. D. (2026). Intelligent virtual agents and the transformation of customer support functions. *Electronic Commerce Research and Applications*.
- Minge, M., Thüring, M., Wagner, I., & Kuhr, C. V. (2017). The meCUE questionnaire: A modular tool for measuring user experience. En S. Yamamoto (Ed.), *Human Interface and the Management of Information* (pp. 115–128). Springer.
- Nielsen, J., & Molich, R. (1990). Heuristic evaluation of user interfaces. *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems*, 249–256. <https://doi.org/10.1145/97243.97281>
- Perumallapalli, R. (2024). Conversational AI for customer support: Automation in large enterprises. *SSRN*. <https://doi.org/10.2139/ssrn.5228517>

Sampaio, T., Oliveira, P. F., & Matos, P. (2025). 3D-chatbot: An intelligent conversational agent integrating RAG, NLP, and VR for commercial stores. *IEEE Conference Proceedings*. <https://doi.org/10.1109/ICEET67911.2025.11424080>

Shin, M., Kim, S. J., & Biocca, F. (2019). The uncanny valley: No need for any further judgments when an avatar looks eerie. *Computers in Human Behavior*, 94, 100–109. <https://doi.org/10.1016/j.chb.2019.01.016>

Tanasă, A.-M., Oprea, S.-V., & Bâra, A. (2024). Designing an architecture of a multi-agentic AI-powered virtual assistant using LLMs and RAG for a medical clinic. *Electronics*, 15(2), 334. <https://doi.org/10.3390/electronics15020334>

ter Stal, S., Tabak, M., op den Akker, H., Beinema, T., & Hermens, H. (2020). Who do you prefer? The effect of age, gender and role on users' first impressions of embodied conversational agents in eHealth. *International Journal of Human-Computer Studies*, 134, 1–12. <https://doi.org/10.1016/j.ijhcs.2019.10.003>

Verhagen, T., van Nes, J., Feldberg, F., & van Dolen, W. (2014). Virtual customer service agents: Using social presence and personalization to shape online service encounters. *Journal of Computer-Mediated Communication*, 19(3), 529–545. <https://doi.org/10.1111/jcc4.12066>

Zhang, Y., Liang, C., & Li, X. (2024). Understanding virtual agents' service quality in the context of customer service: A fit-viability perspective. *Electronic Commerce Research and Applications*. <https://doi.org/10.1016/j.elerap.2024.101380>